

Homework 3

Objetivo: Ler o livro Introdução à Aprendizagem Estatística – com Aplicação em R, disponível em formato PDF. Para preparar as discussões em aula.

1. Leia o capítulo 4 (apenas os tópicos apresentados em aula). Especificamente, faça:
 - a. Identifique pelo menos três perguntas que você possa ter após ler o capítulo. Essas questões devem surgir da falta de compreensão do que foi descrito no parágrafo, exemplos, gráficos, etc.
 - 1) O quanto que os termos Sensitivity e Specificity se diferenciam dos erros tipo 1 e erro tipo 2, ou seriam eles a mesma coisa ?
 - 2) Na figura 4.2 temos uma probabilidade negativa, a princípio eu não entendi o motivo. Depois percebi que era pelo fato de que o modelo de regressão linear não é adequado para problemas no qual a resposta é do tipo qualitativa ou categórica. Tanto que a regressão logística ou a análise discriminante Linear.
 - 3) O KNN é claramente preferível em situações onde não se tem relações simples, por outro lado não apresenta interpretabilidade, diferentemente dos modelos de regressão logística e a Análise discriminante Linear. Existe algum outro método que permita a modelagem de relações não lineares e que permitam a interpretabilidade ? Imagino que seja uma questão complexa, pois um modelo com relações mais complexas depende de mais parâmetros para serem estimados, e conseqüentemente a interpretação tende a ficar mais difícil.
 - b) Identifique pelo menos três pontos discutidos/apresentados no livro (em um parágrafo, nos exemplos ou nos gráficos, etc.) que você considere importantes para outros colegas conhecerem.
 - 1) Um tópico importante e que acredito que muitos não viram ainda e que foi citado no capítulo é a estimação dos parâmetros no modelo logístico via Método de máxima verossimilhança que é um dos mais utilizados na estatística.
 - 2) Com base na Figura 4.8, é importante destacar que uma curva ROC com um desempenho excessivamente alto pode ser um indício de superajuste o conhecido (*overfitting*). Logo, uma análise detalhada é sempre necessária, ressaltando o ponto de que métricas de ajuste perfeitamente altas na curva ROC nem sempre garantem que o modelo terá um bom desempenho no mundo real.
 - 3) Na Análise Discriminante Linear (LDA), deve-se verificar a distribuição dos preditores, pressupondo-se que sejam normalmente distribuídos. Um ponto importante é que, se algum dos preditores tiver um tamanho amostral pequeno, geralmente menor que 30 observações, testes de normalidade existentes, como o de Shapiro-Wilk, perdem a capacidade de distinguir se a distribuição é ou não normal. Isso faz

com que o teste sofra com perda de poder, aumentando o risco de conclusões equivocadas.

Delivery deadline: no later than Tuesday, May 5th. You will have to respond to an electronic file (E.g., Word) and return it to peternelli@ufv.br. Your filename should be stated as follows: HW3_your_first_name.docx. The same filename should be the subject of your email to me, with the file attached.